

Transfer Learning на табличных данных

Введение

Transfer Learning - одна из ключевых тем современного машинного обучения. Она активно применяется в компьютерном слухе, зрении и обработке естественного языка, позволяя переносить знания с больших размеченных датасетов на малые. Однако в области табличных данных эта практика остаётся малоизученной.

Цель данной работы - исследовать возможность переноса знаний между двумя табличными датасетами на примере Adult Census Income (источник) и Bank Marketing (целевой), сравнение обучения с нуля и с классическими методами.

Для этого:

1. Было проведено обучение MLP (многослойный перцептрон) на Adult.
2. Проведен Transfer Learning на Bank (дообучение последнего слоя)
3. Проведено сравнение результатов обучения с нуля и с классическими методами (Logistic Regression, Random Forest, CatBoost).

Гипотезы во время выполнения работы:

1. Transfer Learning между Adult Census и Bank Marketing не даст значимого улучшения качества по сравнению с обучением с нуля. Результат по основной метрике (AP) будет выше не более чем на 0.01.
2. Ансамблевые методы на основе деревьев (CatBoost, Random Forest) покажут более высокое качество по метрике AP (не менее чем на 0.02), чем MLP, на данных Bank Marketing, потому что деревья решений

менее склонны к переобучению при правильной настройке гиперпараметров, тогда как MLP требует значительно больше данных для стабильного обучения и обобщения.

Описание данных

В работе использованы два датасета:

1. Adult Census Income.

- Источник: Kaggle;
- задач: бинарная классификация - превышает ли доход человека

50 тыс. долларов в год;

- 32 561 записей, 14 признаков;
- признаки: возраст, образование, профессия, семейное положение,

доход от капитала.

2. Bank Marketing (small).

- Источник: UCI Machine Learning Repository;
- задача: бинарная классификация - согласится ли клиент на

открытие срочного депозита;

- 4 521 записей, 16 признаков;
- признаки: возраст, профессия, баланс счёта, количество контактов

Сопоставление признаков:

- общие признаки: Age, Education, Financial (balance), Martial Status, Occupation.

В Bank присутствуют признаки, связанные с историей взаимодействия с клиентом - они отсутствуют в Adult.

	Age	Education	Education_Num	Martial_Status	Occupation	Capital_Gain	Capital_Loss
0	39	Bachelors	13	Never-married	Adm-clerical	2174	0
1	50	Bachelors	13	Married-civ-spouse	Exec-managerial	0	0
2	38	HS-grad	9	Divorced	Handlers-cleaners	0	0
3	53	11th	7	Married-civ-spouse	Handlers-cleaners	0	0
4	28	Bachelors	13	Married-civ-spouse	Prof-specialty	0	0
5	37	Masters	14	Married-civ-spouse	Exec-managerial	0	0
6	49	9th	5	Married-spouse-absent	Other-service	0	0
7	52	HS-grad	9	Married-civ-spouse	Exec-managerial	0	0
8	31	Masters	14	Never-married	Prof-specialty	14084	0
9	42	Bachelors	13	Married-civ-spouse	Exec-managerial	5178	0

рисунок 1. Выбранные признаки из Adult датасета

	age	education	marital	job	balance
0	30	primary	married	unemployed	1787
1	33	secondary	married	services	4789
2	35	tertiary	single	management	1350
3	30	tertiary	married	management	1476
4	59	secondary	married	blue-collar	0
5	35	tertiary	single	management	747
6	36	tertiary	married	self-employed	307
7	39	secondary	married	technician	147
8	41	tertiary	married	entrepreneur	221
9	43	primary	married	services	88

рисунок 2. Выбранные признаки из Bank датасета

EDA (первичный анализ данных)

Adult Census Income датасет

Целевая переменная:

- **> 50K**: годовой доход человека превышает 50 000 долларов.
- **<= 50K**: годовой доход человека не превышает 50 000 долларов.




рисунок 3. Гистограмма и круговая диаграмма целевой переменной




рисунок 4. Распределения числовых признаков

Тепловая карта корреляции выбранных признаков Adult датасета:




рисунок 5. Корреляция Adult признаков

Bank Marketing датасет

Целевая переменная:

- **yes:** клиент банка согласился на открытие срочного депозита по результатам маркетинговой кампании.
- **no:** клиент отказался.




рисунок 6. Гистограмма и круговая диаграмма целевой переменной




рисунок 7. Распределения числовых признаков

Тепловая карта корреляции выбранных признаков Bank датасета:




рисунок 8. Корреляция Bank признаков

Методология

Transfer learning эксперименты

В работе были проведены следующие эксперименты:

- заморозка всех слоев сети и дообучение последнего слоя без сброса его весов;
- дообучение последнего слоя со сбросом его весов;
- дообучение последнего слоя без сброса его весов с применением Focal Loss.

Обучение с нуля

Было проведено обучение следующих алгоритмов на Bank Marketing датасете и их сравнение:

- MLP (многослойный перцептрон);
- Logistic Regression;
- Random Forest;
- CatBoost (градиентный бустинг).

Метрики для сравнения

- Average precision (AP) - основная метрика, устойчива к дисбалансу
- F1-score - вспомогательная метрика
- Скорость обучения

Эксперименты и результаты

Предварительное обучение на Adult Census

Был проведен поиск лучшей архитектуры MLP для Adult Census данных и самой оптимальной оказалась архитектура с тремя слоями (512, 256, 128), функцией активации SeLU без Dropout и без Batch Normalization. Лучший AP на валидационной выборке: 0.7836.




рисунок 9. Графики обучения и валидации MLP с лучшими параметрами

Далее были добавлены следующие новые признаки:

- Age_x_Financial - влияние финансов на поведение зависит от возраста;
- Edu_x_Financial - влияние образования на финансы. Их взаимодействие может быть нелинейным;
- Age_sq, Edu_sq - квадраты возраста и образования. Возраст и число образования могут быть также связаны нелинейно.

После добавления этих признаков лучший AP на валидационной выборке был 0.7806. Добавление новых признаков ухудшило качество модели.

Применение Focal Loss почти не изменил основную метрику (AP 0.7838).




рисунок 10. Обучение MLP с применением Focal Loss

С применением Focal Loss графики стали менее хаотичны.

Удаление сильно коррелированного признака лишь незначительно увеличило AP с 0.7838 до 0.7840, что можно списать за погрешность. Это финальная модель.

Дообучение на Bank Marketing

Подход	AP	F1
Без сброса весов последнего слоя	0.1724	0.0617
Со сбросом весов последнего слоя	0.1668	0.0652
Без сброса весов с использованием Focal Loss	0.1968	0.2701

таблица 1. Эксперименты с дообучением MLP модели на Bank Marketing данных




рисунок 11. Графики дообучения MLP модели на Bank Marketing без сброса весов последнего слоя

Обучение с нуля на Bank Marketing

Для задачи датасета Bank Marketing был проведен поиск лучшей архитектуры MLP. Ей оказалась глубокая сеть с 4-мя слоями (128, 64, 32, 16) с функций активации ReLU с Dropout равным 0.3 и без Batch Normalization. Лучшей эпохой оказалась 46 с лучшим AP = 0.5155, а F1 = 0.5455. Дальше модель начала переобучаться.




рисунок 12. Графики обучения лучшей MLP на Bank Marketing данных

В текущей постановке обучение с нуля на целевых данных оказалось эффективнее переноса знаний.

Сравнение MLP с классическими алгоритмами

Было проведено сравнение MLP, обученного с нуля на Bank Marketing данных, с алгоритмами классического машинного обучения.

Модель	AP	F1	Время обучения (сек)
CatBoost with best parameters	0.5671	0.4788	0.6411
CatBoost	0.5552	0.5523	0.6411
MLP	0.5155	0.5455	47.29
Random Forest	0.3469	0.5443	0.29
Logistic Regression	0.3311	0.5211	0.04

таблица 2. Сравнение классических моделей и MLP

Итоги работы

Transfer Learning не дал улучшения качества по сравнению с обучением с нуля, подтвердив первую гипотезу. Основная причина - различие в релевантных признаках. В Bank Marketing ключевую роль играют признаки, связанные с историей взаимодействия с клиентом: число контактов, дни после последнего обращения, результат предыдущей кампании. Эти признаки полностью отсутствуют в Adult, где целевая переменная определяется образованием, семейным положением и возрастом. Даже общие признаки имеют разные распределения, а попытка привести Bank к структуре Adult через маппинг категорий привела к искажению данных. В результате Transfer Learning показал результат в 2.5 раза хуже обучения с нуля ($AP = 0.19$ против 0.5155).

CatBoost показал лучший результат ($AP = 0.5671$), подтвердив вторую гипотезу, так как градиентный бустинг на деревьях лучше работает с небольшими табличными данными: он устойчив к выбросам, учитывает нелинейности. MLP уступил CatBoost всего 0.05 по AP и обучался в 30 раз дольше. Гипотеза о том, что Transfer Learning не даст значимого улучшения, полностью подтвердилась из-за отсутствия общих релевантных признаков, сдвига распределений и разной логики целевых переменных.